

Análise Preditiva da Qualidade da Água

A pergunta do trabalho: Qual será a concentração de Oxigênio Dissolvido (mg/L) na água com base nas medições físico-químicas e ambientais da amostra?

Grupo de Análise da Qualidade de Água

25 de setembro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico | Prof. Dr. João Paulo Ferreira de Mello

Gabrielle Lara Moricz de Souza – RA 0051352511001

Giulia Dias Granado de Marques – RA 0051352511003

Yuri Salgado Pinto – RA 0051352511034

Repositório: <https://github.com/giuliagranado/qualidade-agua>

1 Introdução

O monitoramento da qualidade dos recursos hídricos é fundamental para a preservação de ecossistemas aquáticos e para a garantia da segurança do abastecimento público em regiões metropolitanas (CONAMA, 2005; CETESB, 2022). Em bacias de reservatórios urbanos, como o Complexo Billings, a concentração de Oxigênio Dissolvido (OD) atua como o principal indicador biótico da saúde da água, sendo diretamente influenciada por processos de eutrofização, carga de efluentes, variações de temperatura e precipitação pluviométrica (VON SPERLING, 2014; JAMES et al., 2021). Compreender e antecipar variações na concentração de oxigênio permite identificar processos de anoxia antes que ocorra a mortandade em massa de peixes e a degradação acelerada do ecossistema (BRUCE et al., 2020).

Conforme destacado por Bruce et al. (2020), a escolha da métrica de avaliação e a correta definição da pergunta de pesquisa devem preceder qualquer ajuste de modelos preditivos complexos. Este texto apresenta o banco de dados do projeto (`Dataset_atual.csv`), formula a pergunta central do trabalho e demonstra, por meio de diagnósticos de dados e validação cruzada de 5 dobras, que os dados possuem plenas condições de respondê-la.

2 O banco de dados e o problema

Os dados utilizados foram obtidos a partir do histórico de monitoramento contínuo de estações amostradoras (`Dataset_atual.csv`), contemplando medições efetuadas nos pontos amostradores BILL02900, BIRP00500 e CFUG02900 (CETESB, 2022). Cada linha da tabela representa uma amostragem física de água realizada em uma data e horário específicos. O conjunto bruto contém $n = 48$ observações temporais e $p = 17$ preditores físico-químicos e ambientais válidos (incluindo pH, temperatura, turbidez, nutrientes nitrogenados e fosfatados, sólidos dissolvidos, pluviometria acumulada em 24 h, clorofila-*a* e metais pesados).

A motivação para a escolha deste banco reside no impacto prático direto do problema: a tomada de decisão pelos operadores de Estações de Tratamento de Água (ETA) e pelos gestores da bacia hidrográfica. Antecipar a concentração exata de Oxigênio Dissolvido (Y , em mg/L) fornece suporte operacional direto para acionar sistemas de aeração artificial preventiva e readequar a dosagem de insumos químicos de purificação antes que o fluxo d'água atinja o ponto de captação.

3 A pergunta

Enuncia-se a pergunta central do projeto de forma direta: “Qual será a concentração de Oxigênio Dissolvido (mg/L) na água com base nas medições físico-químicas e ambientais da amostra?” A Tabela 1 detalha os sete campos que a definem.

Tabela 1 – Ficha da pergunta

Campo	Preenchimento
1. A pergunta, em uma frase	Qual será a concentração de Oxigênio Dissolvido (mg/L) na água com base nas medições físico-químicas e ambientais da amostra?
2. Resposta Y : coluna, tipo, unidade	Oxigênio Dissolvido mg/L — quantitativa contínua — mg/L
3. Preditores X : quais e quantos	pH, temperatura, turbidez, nitrogênio total, fósforo total, sólidos, chuva, clorofila- a , metais ($p = 17$)
4. Tipo: as três decisões	Supervisionado; Regressão; Predição
5. A métrica	RMSE (<i>Root Mean Squared Error</i>), em mg/L
6. Linha de base a bater	RMSE = 1,3604 mg/L (desvio-padrão de Y , erro do palpite pela média $\bar{Y} = 8,4785$ mg/L)
7. O dono do problema	Operadores de Estação de Tratamento de Água (ETA) e Gestores de Bacia Hidrográfica

Fonte: Elaborada pelos autores.

4 Defesa da pergunta

A Tabela 2 reúne as quatro verificações feitas sobre o banco de dados.

Vazamento (*Data Leakage*). A análise da matriz de correlação indicou que as maiores associações com o Oxigênio Dissolvido ocorrem com o pH ($r = +0,552$) e a precipitação ($r = -0,534$). Nenhuma coluna apresentou correlação perfeita ou espúria ($r \approx 1,0$), garantindo ausência de vazamento.

Tamanho. Com $n = 48$ amostras e $p = 17$ preditores válidos, a razão $n/p \approx 2,82$ mostra-se restrita. Essa limitação justifica a escolha de modelos parcimoniosos e indica que o uso de técnicas de regularização (Ridge/Lasso) trará ganhos futuros relevantes.

Balanco e faltantes. A variável DBO foi excluída por apresentar 68,75% de dados faltantes. As demais colunas apresentaram preenchimento completo ou residual (imputado pela mediana).

Tabela 2 – Diagnóstico do banco de dados

Verificação	Resultado
Tamanho ($n \times p$)	48×17
Linha de base	RMSE = 1,3604 mg/L (chutar sempre a média)
Maior correlação com Y	pH ($r = +0,552$) e Chuvas nas últimas 24 h ($r = -0,534$)
Balanço das classes	Não se aplica (resposta quantitativa contínua)
Valores faltantes	DBO (33 NAs / 68,75% — excluída); N-Kjeldahl (2 NAs — imputados)

Fonte: Elaborada pelos autores.

Avaliação Numérica por Validação Cruzada (5-Fold CV). Para comprovar o valor preditivo fora da amostra (*out-of-sample*), ajustou-se um modelo de Regressão Linear (**lm**) avaliado via Validação Cruzada de 5 dobras. O modelo obteve um RMSE de 0,8557 mg/L, representando uma redução de 37,10% no erro em relação à linha de base (1,3604 mg/L). Em contrapartida, a abordagem alternativa de classificação binária ($OD \geq 7,0$ mg/L) estagnou no patamar da linha de base (85,11% contra 85,42%), devido ao desbalanceamento das classes (apenas 7 casos críticos em 48).

Veredito. Os resultados numéricos comprovam que a pergunta se sustenta fortemente: o modelo de regressão linear para a concentração de Oxigênio Dissolvido extrai sinal real dos preditores ambientais e supera significativamente o palpite ingênuo da média.

A pergunta é **provisória**: será revista depois da Aula 12, quando o grupo tiver o kit supervisionado completo (modelos de /regularização Lasso/Ridge, árvores de decisão e *ensembles*). No entanto, acreditamos que a pergunta seja realmente interessante por avaliar o que ocorre no caminho entre pontos de coleta e gera um entedimento mais profundo sobre o principal peso no cálculo do IQA.

Referências

BRUCE, P.; BRUCE, A.; GEDECK, I. **Estatística Prática para Cientistas de Dados**: 50 conceitos essenciais. 2. ed. Rio de Janeiro: Alta Books, 2020.

CETESB. **Relatório de Qualidade das Águas Interiores no Estado de São Paulo 2021**. São Paulo: Companhia Ambiental do Estado de São Paulo, 2022.

CONAMA. **Resolução CONAMA nº 357, de 17 de março de 2005**. Dispõe sobre a classificação dos corpos de água e diretrizes ambientais para o seu enquadramento. Brasília, DF: Diário Oficial da União, 2005.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. **An Introduction to Statistical Learning**: with Applications in R. 2. ed. New York: Springer, 2021.

VON SPERLING, M. **Introdução à qualidade das águas e ao tratamento de esgotos**. 4. ed. Belo Horizonte: Editora UFMG, 2014.